

Detecção de Árvores em Imagens Urbanas com YOLO-MS

Guilherme Delmonte (232002539), Gustavo Borges (232002557), Luan Ribeiro (232036958)

Departamento de Ciência da Computação, Universidade de Brasília

Introdução à Inteligência Artificial - Turma 01 - 2025/1

Prof. Díbio Leandro Borges

Brasília, DF, Brasil

Abstract—Este trabalho apresenta uma avaliação rigorosa do detector de objetos YOLO-MS para a tarefa de identificar copas de árvores individuais em imagens RGB de alta resolução. Como uma extensão ao benchmark de Zamboni et al. (2021) [1], este estudo implementa o YOLO-MS, uma arquitetura mais recente, sobre o mesmo conjunto de dados público. Utilizando uma metodologia de validação cruzada com 5-folds para garantir a robustez estatística, o modelo alcançou uma precisão média final (mAP@50) de 0.675 ± 0.004 . Este resultado, caracterizado por uma baixa variância entre os folds, posiciona o YOLO-MS como uma alternativa competitiva e estável aos métodos de estado-da-arte avaliados no estudo original, demonstrando seu potencial para aplicações em monitoramento ambiental e planejamento urbano.

Index Terms—Detecção de Objetos, Deep Learning, YOLO-MS, Sensoriamento Remoto, Detecção de Árvores, Validação Cruzada.

I. INTRODUÇÃO

O mapeamento de árvores em ambientes urbanos é fundamental para a gestão ambiental e o planejamento de cidades sustentáveis. Em um trabalho de referência, Zamboni et al. (2021) [1] realizaram um *benchmark* exaustivo, avaliando 21 arquiteturas de Deep Learning. Este projeto estende essa análise, avaliando o desempenho do YOLO-MS [2], um modelo não testado no estudo original. Nossa contribuição é a avaliação rigorosa do YOLO-MS sob a mesma metodologia, permitindo uma comparação justa com os resultados publicados.

II. METODOLOGIA

A. Base de Dados e Estratégia de Validação

Utilizamos o dataset de Zamboni [3], com 220 imagens aéreas de São José dos Campos, SP. As anotações de segmentação foram convertidas para caixas delimitadoras (*bounding boxes*) no padrão COCO. Para garantir a robustez estatística, adotamos uma metodologia de **validação cruzada com 5-folds**, onde o conjunto de dados completo foi particionado cinco vezes, utilizando a cada rodada 60% dos dados para treino e 20% para teste e 20% para validação.

B. Arquitetura e Configuração Experimental

O **YOLO-MS** [2] foi escolhido por sua arquitetura otimizada para detecção multi-escala, ideal para a variação de

tamanho das copas das árvores. O treinamento foi configurado para replicar as condições do artigo base, garantindo a validade da comparação (Tabela I). O *fine-tuning* foi iniciado a partir de pesos pré-treinados no COCO, estendendo-se por 50 épocas em cada fold para assegurar a completa convergência do modelo. A métrica de avaliação principal foi a AP₅₀ (mAP@50).

TABLE I
PRINCIPAIS HIPERPARÂMETROS DE TREINAMENTO

Parâmetro	Valor
Modelo Pré-treinado	YOLO-MS-M (COCO)
Otimizador	SGD
Taxa de Aprendizagem	0.00125
Momentum	0.9
Weight Decay	0.0001
Épocas por Fold	50
Batch Size	8

III. RESULTADOS E ANÁLISE

A. Resultados Quantitativos

A metodologia de validação cruzada resultou em um desempenho consistente, como detalhado na Tabela II. O modelo alcançou uma performance média final de **0.675 ± 0.004** . A Tabela III posiciona este resultado em relação aos melhores modelos avaliados por Zamboni et al., demonstrando que o YOLO-MS é competitivo, superando os baselines como RetinaNet e Faster R-CNN, e aproximando-se de arquiteturas mais complexas.

TABLE II
RESULTADOS DE MAP@50 DA VALIDAÇÃO CRUZADA

Fold (Run)	Melhor mAP ₅₀
1 (Fold 0)	0.676
2 (Fold 1)	0.682
3 (Fold 2)	0.670
4 (Fold 3)	0.673
5 (Fold 4)	0.675
Média ± Desv. Padrão	0.675 ± 0.004

TABLE III
COMPARAÇÃO COM MODELOS DE REFERÊNCIA (RESULTADOS FINAIS [1])

Modelo	AP ₅₀ (Média)
Double Heads [1]	0.732
ATSS [1]	0.728
Faster R-CNN [1]	0.700
RetinaNet (melhorado) [1]	0.686
YOLO-MS (Este trabalho)	0.675
YOLOv3 [1]	0.591

B. Análise das Curvas de Aprendizado

A Figura 1 e 2 demonstram a estabilidade do processo de treinamento. O mAP@50 atinge um pico, enquanto a perda de treinamento decai de forma consistente, confirmando a convergência do modelo. O baixo desvio padrão, indicado pela área sombreada, corrobora a robustez do método.




Fig. 1. Curva de Performance mAP@50 (Média e Desvio Padrão de 5 Folds).




Fig. 2. Curva de Perda de Treinamento (Média e Desvio Padrão de 5 Folds).

C. Avaliação Visual


A inspeção qualitativa (Fig. 3) revela que o YOLO-MS é eficaz na detecção de árvores com características bem definidas. No entanto, sua performance degrada em cenários complexos, como árvores com folhagem "transparente" (baixa densidade), sobrepostas, ou sob forte sombra, onde algumas detecções são perdidas ou imprecisas.

IV. CONCLUSÃO

Este trabalho demonstrou que o modelo YOLO-MS é uma solução robusta e competitiva para a detecção de copas de árvores, alcançando um mAP@50 médio de 0.675 ± 0.004 através de validação cruzada. A performance é comparável à de arquiteturas de ponta da época do estudo de referência, validando seu potencial para aplicações práticas em sensoriamento remoto. Trabalhos futuros podem explorar *data augmentation* para melhorar a robustez a sombras e oclusão.

REFERENCES

- [1] P. Zamboni, J. M. Junior, J. de Andrade Silva, G. T. Miyoshi, E. T. Matsubara, K. Nogueira, and W. N. Gonçalves, "Benchmarking anchor-based and anchor-free state-of-the-art deep learning methods for individual tree detection in RGB high-resolution images," *Remote Sensing*, vol. 13, no. 13, p. 2482, 2021.
- [2] L. Wang, J.-P. Zhang, Y. Liang, and G.-J. Wang, "YOLO-MS: Rethinking multi-scale representation learning for real-time object detection," <https://arxiv.org/abs/2308.05480v1>, 2023.
- [3] P. Zamboni, "Individual urban tree crown detection dataset," https://github.com/pedrozamboni/individual_urban_tree_crown_detection, 2021.



(a) Exemplo de detecção bem-sucedida.



(b) Falhas em árvores sobrepostas ou em sombra.

Fig. 3. Resultados da inferência. Esquerda de cada par: *ground truth*; direita: previsões do YOLO-MS.